

Exercise 9.16: Penguins - Prior Model

Exercise 9.17: Penguins - Data Exploration

Exercise 9.18: Penguins - Posterior Analysis

Exercise 9.19: Penguins - Posterior Prediction

Exercise 9.20: Penguins - Body Mass Model

Předmět: Bayesiánská analýza (MPE_BAAN)

Code ▼

Třetí úkol, příklad 1 (9.16 - 9.20) - skupina 13

2026-07-14

Exercise 9.16: Penguins - Prior Model

Zdroj: Exercise 9.16 (<https://www.bayesrulesbook.com/chapter-9#exercises-8>)

Dataset `penguins_bayes` v balíčku `bayesrules` obsahuje údaje o 344 tučnících. V následujících cvičeniích použijete tieto dáta na modelovanie dĺžky plutiev tučnícov v mm (Y) na základe dĺžky ich zobákov v mm (X). Máme všeobecnú predstavu, že priemerný tučník má plutvy dlhé niekde medzi 150 mm a 250 mm. Okrem toho nemáme silné predpoklady o vzťahu medzi dĺžkou plutvy a dĺžkou zobáka, a preto pre ostatné parametre využijeme málo informatívne apriórne rozdelenia (weakly informative priors).

- Simulujte apriórny model normálnej regresie pre `flipper_length_mm` na základe `bill_length_mm` pomocou 4 reťazcov (chains) s 10 000 iteráciami pre každý. NÁPOVEDA: Môžete použiť rovnakú syntax `stan_glm()`, akú by ste použili na simuláciu posteriórneho modelu, ale pridajte argument `prior_PD = TRUE`.
- Skontrolujte výstup `prior_summary()` a na jeho základe rozpíšte kompletnú štruktúru vášho modelu normálnej regresie (9.6).
- Vykreslite 100 apriórne možných modelových priamok ($\beta_0 + \beta_1 X$) a 4 datasey simulované z apriórneho modelu.
- Zhrňte vaše málo informatívne apriórne chápanie vzťahu medzi dĺžkou plutvy a dĺžkou zobáka.

a. Apriórny model

Dáta v apriórnom modeli

```
## flipper_length_mm bill_length_mm
## Min. :172.0 Min. :32.10
## 1st Qu.:190.0 1st Qu.:39.23
## Median :197.0 Median :44.45
## Mean :200.9 Mean :43.92
## 3rd Qu.:213.0 3rd Qu.:48.50
## Max. :231.0 Max. :59.60
## NA's :2 NA's :2
```

Nastavenie prior modelu:

- V zadaní je uvedené, že použijeme málo informatívne apriórne modely, keďže máme málo predpokladov o dátach. Preto nastavíme parameter `autoscale` v metóde pre parametre β_1 a σ na `TRUE`. Rstanarm tak automaticky upraví smerodajnú odchýlku pre prior podľa dát.
- Taktiež nemáme predpoklad o smere závislosti, či je kladná alebo záporná. Preto nastavíme strednú hodnotu prioru pre koeficient β_1 na nulu.

ZADANÉ HYPERPARAMETRE:

- Intercept: $m_0 = 200$, $s_0 = 25$ (z intervalu 150 - 250mm)
- Slope: $m_1 = 0$, s_1 - weakly informative (autoscale)
- Sigma: l - weakly informative (autoscale)

APRIÓRNY MODEL:

Data: $Y_i | \beta_0, \beta_1, \sigma \stackrel{ind}{\sim} N(\mu_i, \sigma^2)$ kde $\mu_i = \beta_0 + \beta_1 X_i$
Priors: $\beta_{0c} \sim N(m_0 = 200, s_0^2 = 25^2)$ informatívny
 $\beta_1 \sim N(m_1 = 0, s_1^2)$ málo informatívny
 $\sigma \sim \text{Exp}(l)$ málo informatívny

b. Štruktúra modelu

Vidíme, že po apriórny model sa aktualizoval takto:

- stredná hodnota m_0 a smerodajná odchýlka s_0 pre β_0 sa nezmenili, $N(200, 25)$
- stredná hodnota m_1 pre β_1 sa nezmenila, je stále 0
- smerodajná odchýlka s_1 pre β_1 sa prepočítala: z defaultnej hodnoty 2.5 na 6.44
- parameter σ , ako vstup $1/\sigma$ pre exponenciálne rozdelenie sa prepočítal z 1 na 14.062


APRIÓRNY MODEL sa aktualizoval:

Data: $Y_i | \beta_0, \beta_1, \sigma \stackrel{ind}{\sim} N(\mu_i, \sigma^2)$ kde $\mu_i = \beta_0 + \beta_1 X_i$
Priors: $\beta_{0c} \sim N(m_0 = 200, s_0^2 = 25^2)$
 $\beta_1 \sim N(m_1 = 0, s_1^2 = 6.44)$
 $\sigma \sim \text{Exp}(l = 1/\sigma = 0.07)$

c. Vizualizácia apriórnych modelov


Graf: 100 apriórnych modelových čiar

100 prior lines



Datasets - možné scénare: - každý dataset predstavuje 342 simulovaných hodnôt `flipper_length` pre každého tučniaka vytvorených podľa našej predstavy pred skutočným videním dát - 4 trojice náhodných hodnôt pre hyperparametre z MCMC

4 datasets simulated from prior model



d. Sumarizácia apriórneho pochopenia

Prior model odráža našu neistotu pred preskúmaním dát:

Vieme:

- Typický tučniak má plutvy cca 200mm (150-250mm)

Nevieme:

- Či existuje vzťah medzi zobákom a plutvami
- Ak áno, či je pozitívny alebo negatívny a ako silný

Z prvého grafu 100 priamok:

- 100 priamok rôznej šikmosti: aj rastúce, aj klesajúce
- väčšina čiar prechádza okolo 200 mm pri stredných hodnotách zobáka
- široký rozptyl → veľká neistota

Z grafu - 4 simulované datasety

- 4 simulované datasety ukazujú úplne odlišné scenáre
- Prior je *weakly informative* - nezahŕňa príliš veľké, ani príliš malé nezmyselné hodnoty, ale sú možné rôzne vzťahy

Exercise 9.17: Penguins - Data Exploration


a. Plot and discuss the observed relationship between flipper_length_mm and bill_length_mm among the 344 sampled penguins.

b. Does simple Normal regression seem to be a reasonable approach to modeling this relationship? Explain.

a. Vizualizácia dát

Observed relationship: Flipper vs Bill length

n = 342 penguins



Medzi 342 tučňákmi vidíme pozitívny lineárny vzťah. Korelačný koeficient je $r = 0.656$. Teda `bill length` vysvetľuje približne **43.1%** variability v dĺžke plutvy.

b. Vhodnosť normálnej regresie

Kontrola predpokladov:

1. **Linearita:** Vzťah vyzerá lineárne, nie je viditeľné nejaké zakrivenie.
2. **Normalita a homoskedasticita:** Rozptyl bodov okolo čiary vyzerá približne konštantný.
3. **Nezávislosť:** Každý tučňák predstavuje samostatné pozorovanie.

Jednoduchá normálna regresia je vhodná.


Exercise 9.18: Penguins - Posterior Analysis

- a. Use `stan_glm()` to simulate the Normal regression posterior model.
HINT: You can either do this from scratch or `update()` your prior simulation from Exercise 9.16 using `prior_PD = FALSE`.
- b. Plot 100 posterior model lines for the relationship between flipper and bill length.
- c. Provide a `tidy()` summary of your posterior model, including 90% credible intervals.
- d. Interpret the 90% posterior credible interval for the `bill_length_mm` coefficient, β_1 .
- e. Do we have ample posterior evidence that penguins with longer bills tend to have longer flippers? Explain.

a. Posteriorna simulácia

b. Graf 100 posteriorných priamok

Porovnanie priórnych a posteriorných priamok



c. Tidy summary s 90% CI

Posterior summary with 90% credible intervals

Parameter	Median	90% CI Lower	90% CI Upper
β_0 (Intercept)	126.74	118.99	134.37
β_1 (bill_length_mm)	1.69	1.52	1.86
σ (sigma)	10.64	10.01	11.34
mean_PPD	200.90	199.57	202.25

Posteriorne mediány parametrov:

- **Intercept (β_0):** 126.74 mm
90% CI: [118.99, 134.37]
- **Slope (β_1):** 1.69 mm
90% CI: [1.52, 1.86]
- **Sigma (σ):** 10.64 mm
90% CI: [10.01, 11.34]

d. Interpretácia 90% posteriorného kredibilného intervalu pre β_1

Za každý 1mm nárast v dĺžke zobáka, dĺžka plutiev v priemere narastie o 1.69 mm.

- S 90% pravdepodobnosťou je skutočná hodnota β_1 medzi 1.52 a 1.86 mm. To znamená, že sme si na 90% istí, že za každý 1mm dlhší zobák sú plutvy dlhšie o približne 1.52 až 1.86 mm.

e. Preukázanie posteriorného vzťahu

- Celý interval je **nad nulou** -> čiže silná evidencia pre pozitívny vzťah
- To možno vidieť aj na grafoch 100 priamok, všetky majú pozitívny sklon -> žiadna posteriorna vzorka nenaznačuje negatívny vzťah

Exercise 9.19: Penguins - Posterior Prediction

Suppose we meet Pablo the penguin whose bill is 51mm long.

- Without using the `posterior_predict()` shortcut function, simulate the posterior model for the typical flipper length among penguins with 51mm bills as well as the posterior predictive model for Pablo's flipper length.
- Construct, discuss, and compare density plot visualizations for the two separate posterior models in part a.
- Calculate and interpret an 80% posterior prediction interval for Pablo's flipper length.
- Would the 80% credible interval for the typical flipper length among all penguins with 51mm bills be wider or narrower? Explain.
- Use `posterior_predict()` to confirm your results to parts b and c.

a. Manuálna simulácia predikcie

Odhadnúť dĺžku plutvy, ak poznáme, že bill je 51 mm


Posteriórny model:

$$Y_i | \beta_0, \beta_1, \sigma \stackrel{ind}{\sim} N(\mu_i, \sigma^2) \quad \text{kde} \quad \mu_i = \beta_0 + \beta_1 X_i$$

Dve časti modelu:

- Posterior pre μ_i** (typická dĺžka plutiev pri 51mm zobáku):
 - Len parametrická neistota (β_0, β_1)
 - Median: 212.9 mm
 - 90% CI: [211.7, 214.1]
- Posterior predictive pre Y_i** (odhad Pablovej plutvy):
 - Parametrická neistota + individuálna variabilita (σ)
 - Median: 212.8 mm
 - 90% CI: [199.2, 226.3]

b. Porovnanie posteriorných modelov



c. Prediction interval pre Pabla

80% Posterior predikčný interval: [199.2, 226.3] mm

S 80% pravdepodobnosťou má Pablo plutvy dlhé medzi 199.2 a 226.3 mm.


d. Porovnanie širok intervalov

Kredibilný interval pre typickú dĺžku plutvy je užší, lebo kredibilný interval zahŕňa len neistotu v hodnotách regresných parametrov. Predikčný interval zahŕňa aj individuálnu variabilitu konkrétneho jedinca (Pabla) od typickej hodnoty. Odhad priemeru je v užšom intervale ako odhad jedinca.

- **80% kredibilný interval:** [211.7, 214.1] mm


Typická hodnota je vo vyznačenom intervale:

Posterior typical vs Posterior predictive



e. Overenie pomocou posterior_predict()

Manually vs function posterior_predict



Exercise 9.20: Penguins - Body Mass Model

Instead of bill length, consider the Normal regression model of penguin flipper lengths (Y) by body mass in grams (X).

- Based on their study of penguins in other regions, suppose that researchers are quite certain about the relationship between flipper length and body mass, prior to seeing any data: $\beta_1 \sim N(0.01, 0.002^2)$. Describe their prior understanding.
- Plot and discuss the observed relationship between `flipper_length_mm` and `body_mass_g` among the 344 sampled penguins.
- In a simple Normal regression model of flipper length Y by one predictor X , do you think that the σ parameter is bigger when X = bill length or when X = body mass? Explain your reasoning and provide some evidence from the information you already have.
- Use `stan_glm()` to simulate the Normal regression posterior model of flipper length by body mass using the researchers' prior for β_1 and weakly informative priors for β_{0c} and σ . Do so with 4 chains run for 10000 iterations each.
- Plot the posterior model of the β_1 `body_mass_g` coefficient. Use this to describe the researchers' posterior understanding of the relationship between flippers and mass and how, if at all, this evolved from their prior understanding.

a. Apriórne pochopenie vzťahu

Výskumníci predpokladajú, že $\beta_1 \approx 0.01$ mm/g. To znamená:

- Za každý **1g** nárastu hmotnosti $\rightarrow$ plutvy dlhšie o $0.01 \pm 2 * 0.002$ mm
- Za každý **1kg** $\rightarrow$ plutvy dlhšie o $10 \pm 2 * 2$ mm

95% prior interval: $0.01 \pm 2 * 0.002 = [0.006, 0.014]$

ZADANÉ HYPERPARAMETRE:

- Intercept: $m_0 = 200$, $s_0 = 25$ (z intervalu 150 - 250mm)
- Slope: $m_1 = 0.01$, $s_1 = 0.002$ - informative
- Sigma: l - weakly informative (autoscale)


APRIÓRNY MODEL:

Data: $Y_i | \beta_0, \beta_1, \sigma \stackrel{ind}{\sim} N(\mu_i, \sigma^2)$ kde $\mu_i = \beta_0 + \beta_1 X_i$

Priors: $\beta_{0c} \sim N(m_0 = 200, s_0^2 = 25^2)$ informatívny

$\beta_1 \sim N(m_1 = 0.01, s_1^2 = 0.002^2)$ informatívny


$\sigma \sim \text{Exp}(l)$ málo informatívny



b. Vizualizácia vzťahu flipper length a body mass

Observed relationship: Flipper vs Body mass

n = 342 penguins



Medzi 342 tučňákmi vidíme pozitívny lineárny vzťah. Korelačný koeficient je $r = 0.871$. Teda body_mass_g vysvetľuje približne **75.9%** variability dĺžky plutvy.

c. Porovnanie σ pre rôzne prediktory

σ meria rozptyl okolo priamky: $Y_i \sim N(\beta_0 + \beta_1 X_i, \sigma^2)$

σ je menšia pre body mass model ako pre bill length model.

Keď porovnáme dĺžku plutvy ako závislú premennú od jedného prediktora v jednoduchnej normálnej regresii:

- body mass tesnejšie koreluje s dĺžkou plutvy ako dĺžka zobáka
- na grafe vidno, že body sú tu bližšie ku regresnej priamke
- teda rozptyl od typickej hodnoty je menší

Korelácie:

- Flipper vs Bill length: $r = 0.656$
- Flipper vs Body mass: $r = 0.871$
- Body mass má silnejšiu koreláciu ($0.871 > 0.656$)

d. Posteriorna simulácia s informatívnym priorom


- namiesto weakly informative prioru použijeme prior výskumníkov o β_1 koeficiente

Posterior summary with 90% credible intervals

Parameter	Median	90% CI Lower	90% CI Upper
β_0 (Intercept)	137.879	134.669	141.063
β_1 (body_mass_g)	0.015	0.014	0.016
σ (sigma)	6.927	6.517	7.385
mean_PPD	200.905	200.030	201.777

e. Evolúcia pochopenia vzťahu

- porovnanie pochopenia regresného koeficientu na začiatku v priori a následne v posteriornom modeli.



Evolúcia pochopenia:

Prior: $\beta_1 = 0.01$ (výskumníci očakávali) Posterior: $\beta_1 \approx 0.015$

Posterior je vyšší ako prior.